



Рекомендательная система фильмов

Проектная работа



Цель: разработка и сравнение различных подходов к построению рекомендательной системы фильмов на основе оценок пользователей

Задачи:

- Анализ, предобработка датасета
- Выбор подходящих моделей и их создание
- Тест моделей, оптимизация
- Получение итогового результата

Инструменты:

Библиотеки pandas, seaborn, numpy, sklearn, matplotlib
Google colab, kaggle

Работа над датасетом

• • • • •

Демонстрация датасета

userId	movieId	rating	timestamp
1	110	1.0	1425941529
1	147	4.5	1425942435
1	858	5.0	1425941523
1	1221	5.0	1425941546
1	1246	5.0	1425941556
...	...	...	...
270896	58559	5.0	1257031564
270896	60069	5.0	1257032032

The Movies Dataset

Metadata on over 45,000 movies. 26 million ratings from over 270,000 users.



Data Card Code (766) Discussion (43) Suggestions (3)

About Dataset

Context

These files contain metadata for all 45,000 movies listed in the Full MovieLens Dataset. The dataset consists of movies released on or before July 2017. Data points include cast, crew, plot keywords, budget, revenue, posters, release dates, languages, production companies, countries, TMDb vote counts and vote averages.

This dataset also has files containing 26 million ratings from 270,000 users for all 45,000 movies. Ratings are on a scale of 1-5 and have been obtained from the official GroupLens website.

Usability ⓘ

8.24

License

[CC0: Public Domain](#)

Expected update frequency

Not specified

Tags

adult	belongs_to_collection	budget	genres	homepage	id	imdb_id	original_language	original_title	overview	popularity
False	Toy Story Collection	30000000	Animation,Comedy,Family	http://toystory.disney.com/toy-story	862	tt0114709	en	Toy Story	Led by Woody, Andy's toys live happily in	21.946943

Анализ и проверка


Очистка movies

- 44 дубликата
- 36 сдвинутых строчек
- 3 с отсутствующим id


Очистка ratings

- дубликатов и проблемных строк нет
- 43 700 оценок фильмов которых нет в movies

Распределение средних оценок пользователей (≥ 5 оценок)





Распределение средних оценок пользователей в жанре "Science Fiction" (более 1000 активных пользователей)



Обработка данных


Убраны фильмы с недостаточным количеством оценок




Обработка данных

Убраны пользователи с недостаточным количеством оценок

Процент пользователей по количеству оценок (от 1 до 5)



Распределение количества оценок на пользователя (логарифмическая шкала)



Рекомендательные системы

Хотим, зная предыдущие оценки пользователя, рекомендовать фильмы, которые ему понравятся (релевантные)

- User-based - рекомендуем то, что нравится похожим людям
- Item-based - рекомендуем фильмы, которые похожи на понравившиеся
- ALS - с помощью матриц ищет скрытые характеристики
- LightFm - матричная факторизация с оптимизацией ранжирования

Метрики



Метрики

Precision@k — доля релевантных фильмов среди первых k рекомендаций:

$$\text{Precision@k} = \frac{|\text{Rec}_k \cap \text{Rel}|}{k}$$

Recall@k — доля всех релевантных фильмов, которые попали в первые k рекомендаций:

$$\text{Recall@k} = \frac{|\text{Rec}_k \cap \text{Rel}|}{|\text{Rel}|}$$

NDCG@k — учитывает позицию релевантного фильма (чем выше, тем лучше)

$$\text{NDCG@k} = \frac{\text{DCG@k}}{\text{IDCG@k}}, \quad \text{DCG@k} = \sum_{i=1}^k \frac{\text{rel}_i}{\log_2(i + 1)}$$

Serendipity@k — учитывает одновременно релевантность и неожиданность: релевантный фильм приносит тем больше пользы, чем менее он популярен

$$\text{Serendipity@k} = \frac{1}{k} \sum_{i \in \text{Rec}_k} \text{Relevance}(i) \cdot (1 - \text{Popularity}(i))$$

Гипотезы



Гипотезы

1. Лучшей моделью окажется User-Based, так как в датасете много пользователей
2. Модели которые используются для задач ранжирования будут лучше по NDCG

Модели



Тестирование

Используем пользователей с отзывом среди последних 2\0,2 %

20% его оценок используются для теста, 80% для обучения

Релевантными считаются оценки > 3.5 и не меньше средней для пользователя

Если у пользователя меньше 3 релевантных оценок среди тестовых данных
- не используем его

Baseline

top pop по ratings на 10%
по количеству оценок

title	average_rating
The Shawshank Redemption	4.427742
The Godfather	4.339794
The Usual Suspects	4.300198
Schindler's List	4.266668
The Godfather: Part II	4.263114
Seven Samurai	4.255235
Rear Window	4.232558
12 Angry Men	4.231437
Fight Club	4.230603
One Flew Over the Cuckoo's Nest	4.229118

NDCG@10

0.0315

top pop по imdb
vote_average

title	vote_average
The Godfather	8.5
The Shawshank Redemption	8.5
One Flew Over the Cuckoo's Nest	8.3
Spirited Away	8.3
Fight Club	8.3
The Dark Knight	8.3
Whiplash	8.3
The Godfather: Part II	8.3
Schindler's List	8.3
Life Is Beautiful	8.3

0.0258

random

title	average_rating_from_ratings
Finding Nemo	3.854784
Toy Story	3.888237
One Flew Over the Cuckoo's Nest	4.229118
2001: A Space Odyssey	3.970804
Schindler's List	4.266668
Ocean's Eleven	3.802626
The Lion King	3.804628
Mission: Impossible	3.400086
Taxi Driver	4.089225
Amélie	4.127927

0.0018

4 модели

User-Based

Поиск похожих пользователей

Item-Based

Поиск похожих фильмов

ALS

LightFm


User-based

Пользователю А нравятся те же фильмы, что пользователю В, порекомендуем то что понравилось В

Метрики	k=5	k=10	k=15
Precision	0.2270	0.1908	0.1711
Recall	0.0806	0.1216	0.1540
NDCG	0.2480	0.2348	0.2328
Serendipity	0.0431	0.0374	0.0342

Матрица пользователь - фильм


tmdbId	11	12	13	14	15	18	19
userId							
62441	4.0	4.5	4.0	4.5	4.0	4.0	4.5
134467	NaN	NaN	NaN	5.0	NaN	NaN	NaN
138289	5.0	4.0	4.0	5.0	3.0	NaN	NaN
190589	NaN	4.5	4.5	NaN	NaN	NaN	NaN
219472	NaN	NaN	NaN	NaN	NaN	NaN	NaN




Item-based

Пользователю понравился фильм А,
рекомендуем похожие на А

Матрица сходства фильмов (5 популярных + 5 случайных)



Метрика	k=5	k=10	k=15
Precision	0.1562	0.1332	0.1185
Recall	0.0411	0.0667	0.0868
NDCG	0.1698	0.1572	0.1520
Serendipity	0.0317	0.0273	0.0244



LightFM

1

Разложение матрицы оценок в произведение эмбеддингов пользователей и эмбеддингов фильмов

2

Оценка для пары пользователь-фильм - сумма смещений и скалярного произведения векторов

3

Функция потерь WARP, сравнивает пары примеров

4

Эмбеддинги и смещения обновляются с помощью SGD

@k=5:

Precision: 0.2150
Recall: 0.0537
NDCG: 0.2278
Serendipity: 0.0479

@k=10:


Precision: 0.1894
Recall: 0.0951
NDCG: 0.2160
Serendipity: 0.0430

@k=15:

Precision: 0.1732
Recall: 0.1299
NDCG: 0.2133
Serendipity: 0.0399

ALS

Low-Rank Matrix Factorization:



Iterate:

$$f[i] = \arg \min_{w \in \mathbb{R}^d} \sum_{j \in \text{Nbrs}(i)} (r_{ij} - w^T f[j])^2 + \lambda \|w\|_2^2$$

=== Метрики гибридной модели (ALS + жанры) ===


	k=5	k=10	k=15
Precision	0.117280	0.108700	0.103373
Recall	0.070364	0.124380	0.171007
NDCG	0.125509	0.139677	0.156000
Serendipity	0.035138	0.032401	0.030723

Lgbm

Используем оценки предсказанные моделями

	predicted_rating_ubcf	predicted_rating_ibcf	predicted_rating_lightfm	predicted_rating_als
400602	2.183993	3.574463	0.000000	1.578258
189369	3.583238	3.760236	0.948315	3.359070
154714	3.797573	3.574463	0.000000	2.810551
83590	3.052959	3.574463	0.000000	3.505504
52647	4.424649	3.574463	0.000000	4.639595

оценка от модели	важность
ALS	218
User-based	187
Item-based	116
lightfm	79



Результаты


	baseline	user-based	item-based	lightfm	ALS + жанры	Lgbm
@k=5:						
Precision	0.0516	0.2270	0.1562	0.2150	0.1041	0.334
Recall	0.0113	0.0806	0.0411	0.0537	0.0910	0.1115
NDCG	0.0588	0.2480	0.1692	0.2278	0.1262	0.3923
Serendipity	0.0075	0.0431	0.0317	0.0479	0.0317	0.1256
@k=10:						
Precision	0.0416	0.1908	0.1332	0.1894	0.0948	0.2138
Recall	0.0177	0.1216	0.0667	0.0951	0.1535	0.1275
NDCG	0.0514	0.2348	0.1572	0.2160	0.1444	0.3089
Serendipity	0.0063	0.0374	0.0273	0.0430	0.0319	0.1217
@k=15:						
Precision	0.0354	0.1711	0.1134	0.1732	0.0887	0.1556
Recall	0.0218	0.1540	0.0856	0.1299	0.2042	0.1322
NDCG	0.0475	0.2328	0.1456	0.2133	0.1606	0.2706
Serendipity	0.0055	0.0342	0.0211	0.0399	0.0320	0.1203

Cold start

Симулируем используя пользователей с 5-10 оценками

Для трейна используем 2 самые старые оценки пользователя

Если меньше 2 релевантных среди тестовой выборки - не используем пользователя



	baseline	user-based	item-based	lightfm	ALS + жанры
@k=5:					
Precision	0.045	0.4527	0.1146	0.2411	0.0527
Recall	0.067	0.6954	0.1342	0.2915	0.1317
NDCG	0.072	0.7162	0.1462	0.2975	0.1035
Serendipity	0.0372	0.0952	0.0201	0.0465	0.0111
@k=10:					
Precision	0.0311	0.2573	0.0849	0.1907	0.0426
Recall	0.0914	0.7771	0.1992	0.4581	0.2128
NDCG	0.0821	0.7470	0.1714	0.3727	0.1354
Serendipity	0.0258	0.0548	0.0151	0.0377	0.0090

Выводы



Выводы

- Lgbm стабильно лучшая модель
- User-based лучший среди отдельных моделей
- Чем больше фильмов мы рекомендуем, тем выше шанс покрыть релевантные объекты, Recall растёт. Precision падает, в список добавляются не лучшие рекомендации

Ссылка на репозиторий





<https://github.com/OlgaShehonina/recsys>

Спасибо за
внимание



Идеи развития

1. Создать интерфейс для взаимодействия с моделью
2. Попробовать модели-трансформеры, и LLM
3. Использовать отзывы и тэги для улучшения моделей



Формулы LightFM

$$R_{users \times movies} \approx Q_{users \times d} \times P_{d \times movies}$$

Предсказание оценки вычисляется по формуле:

$$\hat{r}_{ui} = b_u + b_i + q_u \cdot p_i = b_u + b_i + \sum_{k=1}^d q_{uk} \cdot p_{ki}$$

где q_u — вектор пользователя, p_i — вектор фильма.