

Проект

«Рекомендательная система фильмов»

26 июня 2026 г.

Команда: Пронин Михаил, Борцов Михаил, Перфильева Алиса, Шехонина Ольга

1 Краткое описание проекта

Проект — рекомендательная система фильмов на основе датасета MovieLens. Мы реализуем коллаборативную фильтрацию (user-based и item-based), оцениваем матрицу совместной встречаемости, вычисляем метрику precision@k , recall@k , NDSG@k , Serendipity ($k = 5, 10, 15$), а также исследуем проблему холодного старта (cold start) в качестве бонуса.

Постановка задачи: тип задачи — ранжирование (ranking). На вход подаются оценки пользователей фильмов (плюс метаданные о фильмах). На выходе мы хотим получить топ-5, 10 или 15 фильмов, которые рекомендуем конкретному пользователю. Качество моделей проверяется на 2% пользователей (отложенная выборка).

Данные: основной датасет — MovieLens (несколько таблиц: пользователи, фильмы, оценки, теги). В нём большое количество данных (сотни тысяч оценок) и дополнительная информация о фильмах (жанры, год выпуска). После первичного анализа выбросов и искажённых строк не обнаружено, поэтому датасет взят как основной. Альтернативные датасеты либо меньше по размеру, либо ориентированы на текст, что не подходит для нашей задачи.

Инструменты: Python, Google Colab, Kaggle; библиотеки pandas, numpy, scikit-learn, seaborn, matplotlib, а также специализированные пакеты для рекомендаций (LightFM, implicit). Код выложен в открытый репозиторий [GitHub](#).

Проект ориентирован на исследование различных подходов к коллаборативной фильтрации и может быть адаптирован для реальных онлайн-кинотеатров, где требуется персонализированная выдача фильмов.

2 Конкуренты и аналоги

В таблице [1](#) приведены результаты известных рекомендательных моделей на датасете MovieLens-1M (из открытых источников). Это позволяет оценить место наших моделей в контексте современных подходов.

3 Описание функциональностей проекта

1. **Загрузка и первичный анализ данных** — импорт таблиц, визуализация распределений, поиск аномалий.
2. **Предобработка** — удаление дубликатов (44 в movies, 36 сдвинутых строк, 3 без ID), очистка рейтингов (удалено 43 700 оценок фильмов, отсутствующих в movies), фильтрация фильмов и пользователей с малым числом оценок.
3. **Разделение выборки** — 80% оценок на обучение, 20% на тест. Релевантными считаются оценки > 3.5 и не ниже среднего пользователя. Пользователи с < 3 релевантными оценками в тесте исключаются.
4. **Бейзлайны** — top-pop по общему числу оценок, top-pop по среднему рейтингу IMDb, случайные рекомендации.
5. **Четыре основных модели:**
 - *User-based*: косинусная мера схожести между пользователями, предсказание как взвешенное среднее оценок соседей.
 - *Item-based*: косинусная близость между фильмами, предсказание на основе оценок пользователя для похожих фильмов.
 - *ALS (Alternating Least Squares)*: матричная факторизация с регуляризацией, оптимизация попеременным методом наименьших квадратов.
 - *LightFM*: Матричная факторизация с оптимизацией ранжирования через WARP и SGD
6. **Оценка качества** — расчёт метрик Precision@k, Recall@k, NDCG@k, Serendipity. для k(5,10,15)
7. **Симуляция cold start** — для пользователей с 5–10 оценками оставляем только 2 самые старые для обучения, остальное — тест; анализируем падение качества.
8. **Реализация гибридной модели** — объединяем 4 модели.
9. **Визуализация результатов** — гистограммы, графики сравнения, тепловые карты.
10. **Экспорт моделей** — сериализация для возможного использования в веб-сервисе.

4 Библиотеки

Таблица 2: Библиотеки, используемые в проекте

Назначение	Библиотека	Альтернативы	Почему выбрали эту библиотеку
Обработка данных и таблиц	pandas, numpy	—	Стандартные инструменты для работы с табличными данными (CSV, фильтрация, группировки) и числовыми массивами. Используются во всех ноутбуках.
Работа с разреженными матрицами	scipy.sparse (csr_matrix, coo_matrix)	pandas.sparse	Эффективное хранение и обработка больших матриц пользователь-фильм (миллионы оценок) с минимальным потреблением памяти. Используется в ALS, UBCF, LightFM.
Машинное обучение и метрики	scikit-learn (NearestNeighbors, train_test_split)	implicit, surprise	NearestNeighbors для быстрого поиска похожих пользователей в UBCF, train_test_split для разбиения выборок. Встроенные метрики не использовались, но библиотека даёт удобные инструменты для предобработки.
Матричная факторизация (ALS)	implicit (ALS)	surprise (SVD), tensorflow/pytorch	Реализация ALS с поддержкой разреженных матриц и многопоточности, что критично для больших данных. Быстрее, чем аналоги на чистом Python.
LightFM	lightfm-next (форк lightfm)	spotlight, fastai.collab	LightFM позволяет использовать коллаборативную фильтрацию с оптимизацией ранжирования (WARP), что даёт высокую точность в топе рекомендаций. lightfm-next — актуальная версия с исправлениями.
Загрузка датасета	kagglehub	gdown, requests + ручное скачивание	Официальный инструмент Kaggle для скачивания датасетов прямо в ноутбук. Упрощает воспроизводимость (данные всегда свежие).
Визуализация	matplotlib, seaborn	plotly, bokeh	Используются для построения гистограмм, графиков распределений и сравнения метрик (в коде присутствуют импорты, даже если не во всех ячейках запущены).

Продолжение на следующей странице

Назначение	Библиотека	Альтернативы	Почему выбрали эту библиотеку
Прогресс-бары	tqdm (включая tqdm.notebook)	progressbar2, alive-progress	Удобное отображение прогресса при итерациях по пользователям в UBCF и LightFM, особенно важно при длительных вычислениях.
Обработка строк и JSON	ast (literal_eval)	json, yaml	Используется для парсинга столбцов с метаданными (жанры, актёры), которые хранятся в виде строковых списков. ast.literal_eval безопаснее, чем eval().
Управление памятью	gc (garbage collector)	ручное удаление переменных (del)	Явный вызов сборщика мусора помогает освободить память после загрузки больших DataFrame и матриц, что особенно важно в Kaggle/Colab.
Системные утилиты	os, warnings, time	–	Стандартные модули для работы с файловой системой, подавления предупреждений и замера времени выполнения.

5 MVP (Minimal Viable Product)

- Загрузка и предобработка датасета.
- Разделение на train/test (80/20).
- Реализация трёх бейзлайнов.
- Реализация четырёх моделей (User-based, Item-based, ALS, LightFM).
- Расчёт Precision, Recall, NDCG, Serendipity на тесте.
- Сравнительный анализ результатов.
- Симуляция cold-start сценария.
- Реализация гибридной модели.
- Итоговые выводы и рекомендации по выбору модели.
- Публикация кода и отчёта на GitHub.

6 Гипотезы проекта

В процессе работы были выдвинуты следующие предположения:

- Модели на основе коллаборативной фильтрации (особенно с учётом скрытых факторов) покажут значительное превосходство над бейзлайнами.

- User-based подход может дать более персонализированные рекомендации для активных пользователей, но будет страдать от разреженности данных.
- Item-based модель окажется более стабильной при большом количестве фильмов.
- ALS (матричная факторизация) обеспечит наилучшее качество при достаточном объёме данных, но потребует больше времени на обучение.
- Метрика Serendipity (неожиданность рекомендаций) будет выше у моделей, учитывающих разнообразие жанров.

7 План работы по неделям

Неделя	Выполненные задачи
(13–19 апр.)	Выбор датасета (MovieLens).
(20–26 апр.)	Обработка датасета: удаление дубликатов, проверка на выбросы и пропуски.
(27 апр. – 3 мая)	Анализ данных: поиск закономерностей.
(4–10 мая)	Создание baseline. Изучение разных моделей, каждый участник реализует свою и сравнивает с baseline.
(11–17 мая)	Проверка и доработка моделей, настройка гиперпараметров.
(18–24 мая)	Первые результаты, формулировка гипотез, запуск дополнительных экспериментов.
(25–31 мая)	Создание cold start.
(1–7 июня)	Финальное сравнение всех моделей, создание лучшей.
(8–14 июня)	Подготовка итоговой презентации и финального отчёта.

8 Разделение обязанностей

- **Пронин Михаил** — общий анализ данных, реализация baseline (top-pop), разработка user-based модели, проверка влияния количества соседей на качество.
- **Борцов Михаил** — реализация ALS модели, подбор числа факторов и регуляризации, оптимизация производительности.
- **Перфильева Алиса** — реализация item-based модели, предобработка для item-based, сравнение с user-based.
- **Шехонина Ольга** — реализация LightFM как коллаборативной модели (матричная факторизация + WARP), интеграция кода.
- **Общие задачи** — реализация итоговой модели, проверка каждой из моделей на cold-start. Составление выводов. Оформление презентации и итогового документа.

9 Ожидаемые результаты и применение

Мы ожидаем получить рекомендательную систему, которая значительно превосходит простые бейзлайны. Итоговый продукт сможет относительно успешно симулировать рекомендации фильмов на основе введённых оценок пользователя. В перспективе система может быть встроена в веб-сервис для кинопросмотра, где пользователи получают персонализированные подборки.

Итоговый вывод

Лучшей моделью по совокупности метрик оказалась User-based, показавшая наибольший NDCG@5. ALS также продемонстрировал высокое качество, особенно при работе с разреженными данными. LightFM показал неплохие результаты с учетом времени и ресурсов потраченных на обучение. Item-based модели проще интерпретировать, но они менее устойчивы к холодному старту. Результаты подтверждают, что гибридный подход с учётом признаков объектов даёт преимущество в задачах рекомендации фильмов и открывает путь для дальнейшего улучшения системы.

Таблица 1: Сравнение с литературными моделями на MovieLens-1M

Модель	Датасет	Метрика	Значение
LightGCN	MovieLens-1M	NDCG@10	0.2007
LightGCN	MovieLens-1M	Recall@10	0.1507
LightGCN	MovieLens-1M	NDCG@20	0.3009
LightGCN	MovieLens-1M	Recall@20	0.2789
LightGCN	MovieLens-1M	Precision@20	0.1831
NGCF	MovieLens-1M	NDCG@10	0.254
NGCF	MovieLens-1M	Recall@10	0.162
NGCF	MovieLens-1M	NDCG@20	0.2711
NGCF	MovieLens-1M	Recall@20	0.2640
NGCF	MovieLens-1M	Precision@20	0.1643
SASRec	MovieLens-1M	NDCG@10	0.167 (с BCE)
SASRec	MovieLens-1M	Recall@1	0.0769 (с gBCE)
BERT4Rec	MovieLens-1M	NDCG@10	0.154 (с gBCE)
BERT4Rec	MovieLens-1M	Recall@1	0.059 (с gBCE)
NeuMF	MovieLens-1M	NDCG@20	0.2465
NeuMF	MovieLens-1M	Recall@20	0.2369
NeuMF	MovieLens-1M	Precision@20	0.1553
GCMC	MovieLens-1M	NDCG@10	0.240
GCMC	MovieLens-1M	Recall@10	0.152
GCMC	MovieLens-1M	NDCG@20	0.2647
GCMC	MovieLens-1M	Recall@20	0.2548
GCMC	MovieLens-1M	Precision@20	0.1629
ConvNCF	MovieLens-1M	NDCG@10	0.128
ConvNCF	MovieLens-1M	Recall@10	0.073
ConvNCF	MovieLens-1M	NDCG@20	0.1229
ConvNCF	MovieLens-1M	Recall@20	0.1134
ConvNCF	MovieLens-1M	Precision@20	0.0826
MF	MovieLens-1M	NDCG@20	0.2661
MF	MovieLens-1M	Recall@20	0.2493
MF	MovieLens-1M	Precision@20	0.1636